

Теория и практика DWH:

основные ценности подхода Кимбалла

и

сравнение с другими подходами

Что обсудим:

- Вступление:
 - что такое теория и практика DWH, зачем это нужно
 - кто такой Кимбалл, его книги
- Основная часть:
 - основные ценности подхода Кимбалла
 - кто такой Инмон?
 - что такое Data Mesh?
 - интересный факт
 - Инмон, Кимбалл vs Data Mesh
- Источники

Вступление



Что такое теория и практика DWH, зачем это нужно?

Представим себя в компьютерной игре.

Если у нас есть что-то одно (только теория или только практика), мы видим:



Если есть и теория, и практика, мы расширяем/дополняем свой обзор:



Если есть и теория, и практика, мы расширяем/дополняем свой обзор:



Сегодня мы расширим/дополним свой обзор на тему:

основные ценности подхода Кимбалла

и

Сегодня мы расширим/дополним свой обзор на тему:

основные ценности подхода Кимбалла

и


сравнение с другими подходами

Кто такой Кимбалл?

Ральф Кимбалл - автор методологии размерного моделирования (dimensional modeling), которая стала одной из двух основных подходов к проектированию хранилищ данных.





Основной его труд – это книга «The Data Warehouse Toolkit»



В переводе эта книга выглядит так:



Здесь и далее, говоря «Кимбалл», будем иметь ввиду его подход:



Основная часть



хорошо то хранилище, которым пользуются

Деловое сообщество должно принять систему DW/BI, чтобы считать её успешной. Неважно, что вы создали элегантное решение, используя лучшие в своём роде продукты и платформы. Если бизнес-сообщество не принимает эту DW/BI-среду и не использует её активно, вы не прошли вступительный тест

глава 1, стр.37

Успех DW/BI напрямую связан с признанием бизнеса. Если пользователи не приняли систему DW/BI в качестве основы для улучшения процесса принятия решений, ваши усилия оказались тщетными

глава 17, стр. 521

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы
- простота и понятность для пользователей

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы
- простота и понятность для пользователей
- быстрота выполнения запросов

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы
- простота и понятность для пользователей
- быстрота выполнения запросов
- инкрементальная разработка (снизу вверх)

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы
- простота и понятность для пользователей
- быстрота выполнения запросов
- инкрементальная разработка (снизу вверх)
- единый источник правды
через согласованные измерения

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы
- простота и понятность для пользователей
- быстрота выполнения запросов
- инкрементальная разработка (снизу вверх)
- единый источник правды
через согласованные измерения
- сохранение истории изменений

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы —

хранилище проектируется вокруг реальных бизнес-событий (продажи, звонки, отгрузки), а не структуры исходных баз данных.
- простота и понятность для пользователей
- быстрота выполнения запросов
- инкрементальная разработка (снизу вверх)
- единый источник правды
через согласованные измерения
- сохранение истории изменений

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы — хранилище проектируется вокруг реальных бизнес-событий (продажи, звонки, отгрузки), а не структуры исходных баз данных.
- простота и понятность для пользователей — данные организуются в виде таблиц фактов (числа, метрики) и измерений (контекст: кто, где, когда). Такая структура интуитивно понятна бизнес-аналитикам.
- быстрота выполнения запросов
- инкрементальная разработка (снизу вверх)
- единый источник правды
через согласованные измерения
- сохранение истории изменений

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы — хранилище проектируется вокруг реальных бизнес-событий (продажи, звонки, отгрузки), а не структуры исходных баз данных.
- простота и понятность для пользователей — данные организуются в виде таблиц фактов (числа, метрики) и измерений (контекст: кто, где, когда). Такая структура интуитивно понятна бизнес-аналитикам.
- быстрота выполнения запросов — схема «звезда» (Star Schema) и схема «снежинка» сводят к минимуму количество сложных объединений (JOIN) таблиц, что ускоряет работу BI-инструментов.
- инкрементальная разработка (снизу вверх)
- единый источник правды
через согласованные измерения
- сохранение истории изменений

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы — хранилище проектируется вокруг реальных бизнес-событий (продажи, звонки, отгрузки), а не структуры исходных баз данных.
- простота и понятность для пользователей — данные организуются в виде таблиц фактов (числа, метрики) и измерений (контекст: кто, где, когда). Такая структура интуитивно понятна бизнес-аналитикам.
- быстрота выполнения запросов — схема «звезда» (Star Schema) и схема «снежинка» сводят к минимуму количество сложных объединений (JOIN) таблиц, что ускоряет работу BI-инструментов.
- инкрементальная разработка (снизу вверх) — хранилище строится постепенно. Сначала создаются небольшие тематические витрины данных (Data Marts) для отдельных отделов, которые затем объединяются в общую сеть.
- единый источник правды
через согласованные измерения
- сохранение истории изменений

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы — хранилище проектируется вокруг реальных бизнес-событий (продажи, звонки, отгрузки), а не структуры исходных баз данных.
- простота и понятность для пользователей — данные организуются в виде таблиц фактов (числа, метрики) и измерений (контекст: кто, где, когда). Такая структура интуитивно понятна бизнес-аналитикам.
- быстрота выполнения запросов — схема «звезда» (Star Schema) и схема «снежинка» сводят к минимуму количество сложных объединений (JOIN) таблиц, что ускоряет работу BI-инструментов.
- инкрементальная разработка (снизу вверх) — хранилище строится постепенно. Сначала создаются небольшие тематические витрины данных (Data Marts) для отдельных отделов, которые затем объединяются в общую сеть.
- единый источник правды через согласованные измерения — для интеграции разных витрин используются согласованные измерения (Conformed Dimensions) — например, единое для всей компании измерение «Клиенты».
- сохранение истории изменений

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы — хранилище проектируется вокруг реальных бизнес-событий (продажи, звонки, отгрузки), а не структуры исходных баз данных.
- простота и понятность для пользователей — данные организуются в виде таблиц фактов (числа, метрики) и измерений (контекст: кто, где, когда). Такая структура интуитивно понятна бизнес-аналитикам.
- быстрота выполнения запросов — схема «звезда» (Star Schema) и схема «снежинка» сводят к минимуму количество сложных объединений (JOIN) таблиц, что ускоряет работу BI-инструментов.
- инкрементальная разработка (снизу вверх) — хранилище строится постепенно. Сначала создаются небольшие тематические витрины данных (Data Marts) для отдельных отделов, которые затем объединяются в общую сеть.
- единый источник правды через согласованные измерения — для интеграции разных витрин используются согласованные измерения (Conformed Dimensions) — например, единое для всей компании измерение «Клиенты».
- сохранение истории изменений — методология включает в себя механизмы обработки медленно меняющихся измерений (SCD — Slowly Changing Dimensions), что позволяет точно оценивать исторические данные.

всё познаётся в сравнении...

Сравним подход Кимбалла с:

- подходом Инмона
- Data Mesh

Кто такой Инмон?



A portrait of Bill Inmon, a man with grey hair and a mustache, wearing a green jacket. The portrait is set within a rounded rectangular frame on a dark background.

Meet Bill Inmon

- Widely known as the father of the data warehouse
- The first to define data as more than transaction processing
- One of the original voices behind ETL, data warehousing, and analytical thinking

Helping businesses turn data into a single version of truth — long before it was fashionable

INSANE DATA

Navigation icons: back, forward, and a series of four dots at the bottom.

Кто такой Инмон?

Билл Инмон — американский компьютерный ученый, который считается «отцом хранилищ данных» (Data Warehouse).



Meet Bill Inmon

- Widely known as the father of the data warehouse
- The first to define data as more than transaction processing
- One of the original voices behind ETL, data warehousing, and analytical thinking

Helping businesses turn data into a single version of truth — long before it was fashionable

INSANE DATA

Four dots at the bottom indicate the current slide position.

Кто такой Инмон?

Билл Инмон — американский компьютерный ученый, который считается «отцом хранилищ данных» (Data Warehouse).

В 1991 году он написал первую книгу на эту тему и сформулировал классическое определение DWH.



Meet Bill Inmon

- Widely known as the father of the data warehouse
- The first to define data as more than transaction processing
- One of the original voices behind ETL, data warehousing, and analytical thinking

Helping businesses turn data into a single version of truth — long before it was fashionable

INSANE DATA

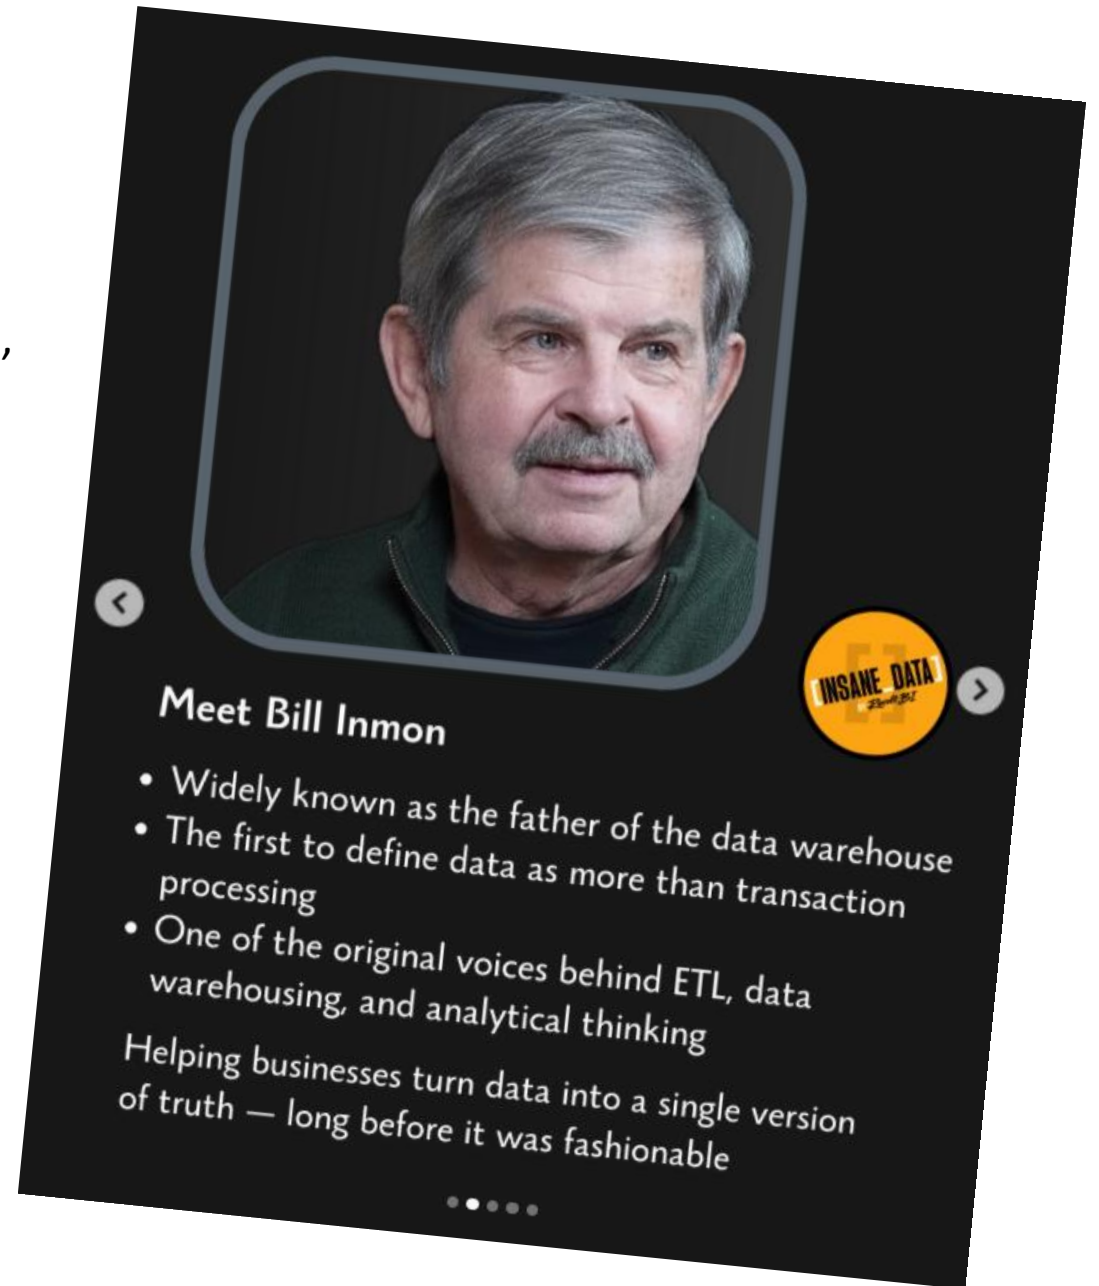
Кто такой Инмон?

Билл Инмон — американский компьютерный ученый, который считается «отцом хранилищ данных» (Data Warehouse).

В 1991 году он написал первую книгу на эту тему и сформулировал классическое определение DWH.

4 основных свойства DWH:

- предметно-ориентированность
- интегрированность
- зависимость от времени (историчность)
- неизменяемость



Кто такой Инмон?

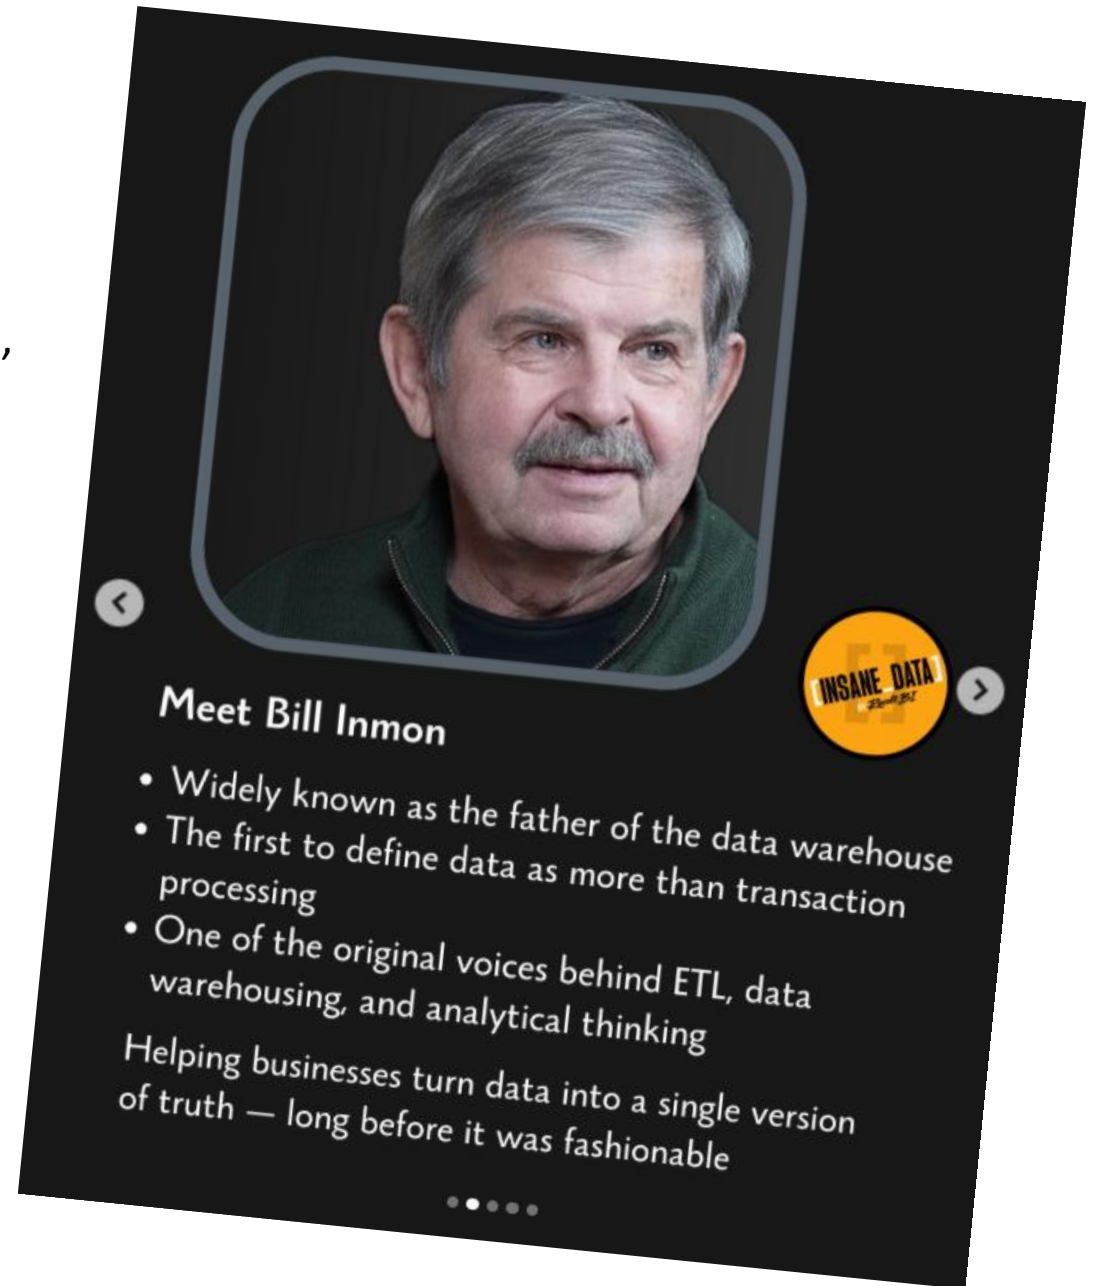
Билл Инмон — американский компьютерный ученый, который считается «отцом хранилищ данных» (Data Warehouse).

В 1991 году он написал первую книгу на эту тему и сформулировал классическое определение DWH.

4 основных свойства DWH:

- предметно-ориентированность
- интегрированность
- зависимость от времени (историчность)
- неизменяемость

Его методология считается фундаментальной для крупных корпораций, где критически важны строгая отчетность и единый стандарт данных.



Что такое Data Mesh?

Data Mesh (сетка данных) — это архитектурный подход, который децентрализует управление данными.

Что такое Data Mesh?

Data Mesh (сетка данных) — это архитектурный подход, который децентрализует управление данными.

Автор концепции Data Mesh — Жамак Дегани (Zhamak Dehghani), на момент появления концепции (2019) занимавшая пост директора по новым технологиям в международной консалтинговой IT-компании Thoughtworks.



Что такое Data Mesh?

Data Mesh (сетка данных) — это архитектурный подход, который децентрализует управление данными.

Автор концепции Data Mesh — Жамак Дегани (Zhamak Dehghani), на момент появления концепции (2019) занимавшая пост директора по новым технологиям в международной консалтинговой IT-компании Thoughtworks.

Главные принципы Data Mesh:

- принцип доменного владения
- принцип данных как продукта
- принцип платформы данных самообслуживания
- принцип федеративного цифрового регулирования данных



интересный факт - апелляция к авторитету

Альберт Эйнштейн сформировал основную философию, управляющую размерным дизайном, когда сказал:
«Всё следует **упрощать** до тех пор, пока это возможно, но не более того».

Кимбалл, глава 1, стр. 41

интересный факт - апелляция к авторитету

Альберт Эйнштейн сформировал основную философию, управляющую размерным дизайном, когда сказал:
«Всё следует **упрощать** до тех пор, пока это возможно, но не более того».

Кимбалл, глава 1, стр. 41

«Высшей целью любой теории является **упрощение** минимальных базовых элементов, насколько это возможно без потери репрезентативной адекватности простой единицы опыта –
»

Дегани, часть III, предисловие, стр. 181

интересный факт - апелляция к авторитету

Альберт Эйнштейн сформировал основную философию, управляющую размерным дизайном, когда сказал:
«Всё следует **упрощать** до тех пор, пока это возможно, но не более того».

Кимбалл, глава 1, стр. 41


«Высшей целью любой теории является **упрощение** минимальных базовых элементов, насколько это возможно без потери репрезентативной адекватности простой единицы опыта –
Альберт Эйнштейн»

Дегани, часть III, предисловие, стр. 181

интересный факт - апелляция к авторитету

Альберт Эйнштейн сформировал основную философию, управляющую размерным дизайном, когда сказал:
«Всё следует **упрощать** до тех пор, пока это возможно, но не более того».

Кимбалл, глава 1, стр. 41



«Высшей целью любой теории является **упрощение** минимальных базовых элементов, насколько это возможно без потери репрезентативной адекватности простой единицы опыта – **Альберт Эйнштейн**»

Дегани, часть III, предисловие, стр. 181

Инмон, Кимбалл vs Data Mesh

Критерий	Билл Инмон (Bill Inmon)	Ральф Кимбалл (Ralph Kimball)	Data Mesh (Концепция)
Основная концепция	Единое централизованное корпоративное хранилище (EDW). Источник «правды» находится в одной системе.	Децентрализованные витрины данных (Data Marts), ориентированные на бизнес-процессы.	Децентрализованные домены, где данные рассматриваются как продукт конкретной команды.
Подход к проектированию	Сверху вниз (Top-Down). Сначала проектируется глобальная нормализованная модель данных, затем из нее строятся витрины.	Снизу вверх (Bottom-Up). Сначала создаются витрины под конкретные задачи отделов, которые затем связываются через общие измерения.	Доменно-ориентированный . Каждый домен бизнеса (например, продажи, логистика) самостоятельно владеет и управляет своими данными.
Моделирование данных	Нормализованная модель (3NF – третья нормальная форма), отсутствие дублирования данных.	Схемы типа «Звезда» (Star Schema) или «Снежинка» (Snowflake), высокая денормализация для скорости.	Гибкое, нет единого стандарта — домены сами выбирают подходящие модели (часто используются графы, NoSQL или реляционные базы).
Управление (Governance)	Централизованное . Строгие корпоративные стандарты. Единый отдел хранилищ данных (DWH Team) контролирует все изменения.	Гибридное . Разработка децентрализована, но есть строгие стандарты на глобальные (общие) измерения и справочники.	Федеративное . Единые глобальные правила безопасности и совместимости, а реализация и управление отданы доменным командам.
Ответственность и Владение	Центральная команда разработки (ETL-разработчики и архитекторы).	Центральная команда хранилищ отвечает за сбор данных, аналитики — за витрины.	Кросс-функциональные команды доменов (Domain-oriented ownership): аналитики, дата-инженеры и Data Product Owner'ы.

Инмон, Кимбалл vs Data Mesh


Критерий	Билл Инмон (Bill Inmon)	Ральф Кимбалл (Ralph Kimball)	Data Mesh (Концепция)
Масштабируемость	Низкая/Средняя. Требуется значительных усилий для перестройки глобальной схемы данных при расширении.	Хорошая. Добавление новой витрины не ломает существующую отчетность, если соблюдаются правила измерений.	Высокая. Легко масштабируется при росте организации за счет подключения новых доменов и независимых дата-продуктов.
Сложность внедрения	Высокая. Долгий старт, долгая окупаемость. Требуется глубокого анализа всех процессов компании до начала загрузки.	Средняя. Быстрее дает результат для бизнеса, так как закрывает конкретные боли отдельных подразделений.	Очень высокая. Культурный сдвиг компании. Требуется зрелых процессов, высокой квалификации кадров и перестройки всей ИТ-структуры.
Главные преимущества	Высокая надежность, единый источник, отсутствие противоречивых данных, глубокая историчность.	Гибкость, быстрота настройки аналитики, простота использования (интуитивно понятно для бизнес-пользователей).	Устранение узких мест (нет перегруженного центрального отдела данных), независимость, высокая адаптивность к изменениям в бизнесе.
Главные недостатки	Долгое время реализации, сложность модернизации, сильная зависимость от централизованного ИТ-отдела.	Риск появления изолированных «островков данных» (Data Silos), дублирование логики и затрат на хранение в разных витринах.	Множество дублирующихся усилий/ресурсов, сложность обеспечения целостной картины на уровне всей корпорации.
Оптимальный выбор	Крупные enterprise-компании со строгими требованиями к безопасности и единой отчетностью (банки, тяжелая промышленность).	Средний и крупный бизнес, с четким фокусом на подразделения и необходимостью быстрого доступа к аналитике.	Очень крупные, динамично растущие экосистемы (ИТ-гиганты, маркетплейсы), где централизованные системы становятся "бутылочным горлышком".

ИСТОЧНИКИ





Источники

О подходе Кимбалла можно прочитать здесь:



Источники

О подходе Инмона:



Источники

Data Mesh:

O'REILLY®

Data Mesh

Новая парадигма работы с данными



FOLIANT

Жамак Дегани

Источники

Сравнение подходов присутствует в:



Спасибо
за внимание

