

Теория и практика DWH:

Кимбалл и очень_важная_витрина

Что обсудим:

- Вступление:
 - Что такое теория и практика DWH, зачем это нужно
 - Кто такой Кимбалл
 - Что такое *очень_важная_витрина*
- Основная часть:
 - Что такое *очень_важная_витрина* по Кимбаллу
 - Что внутри
 - Задача со звёздочкой
- Выводы:
 - Что хорошо
 - Что плохо (проблемы/зоны роста)
 - Выводы

Вступление



Что такое теория и практика DWH, зачем это нужно?

Представим себя в компьютерной игре.


Если у нас есть что-то одно (только теория или только практика), мы видим:



Если есть и теория, и практика, мы расширяем/дополняем свой обзор:



Если есть и теория, и практика, мы расширяем/дополняем свой обзор:



Сегодня мы расширим/дополним свой обзор на тему:

Сегодня мы расширим/дополним свой обзор на тему:

Кимбалл

и

Сегодня мы расширим/дополним свой обзор на тему:

Кимбалл

и


очень_важная_витрина

Кто такой Кимбалл?

Ральф Кимбалл - автор методологии размерного моделирования (dimensional modeling), которая стала одной из двух основных подходов к проектированию хранилищ данных.





Основной его труд – это книга «The Data Warehouse Toolkit»



В переводе эта книга выглядит так:



Здесь и далее, говоря «Кимбалл», будем иметь ввиду его подход:



Что такое *очень_важная_витрина?*

Что такое *очень_важная_витрина*?

- широкая витрина с агрегатами

Что такое *очень_важная_витрина*?

- широкая витрина с агрегатами
- детализация по пользователям (и устройствам)

Что такое *очень_важная_витрина*?

- широкая витрина с агрегатами
- детализация по пользователям (и устройствам)
- пополняется раз в день

Что такое *очень_важная_витрина*?

- широкая витрина с агрегатами
- детализация по пользователям (и устройствам)
- пополняется раз в день

... а если по Кимбаллу?



Основная часть



Что такое *очень_важная_витрина*
по Кимбаллу?

Что такое *очень_важная_витрина*
по Кимбаллу?

- таблица фактов

Что такое *очень_важная_витрина*
по Кимбаллу?

- таблица фактов
- агрегированная

Что такое *очень_важная_витрина*
по Кимбаллу?

- таблица фактов
- агрегированная
- консолидированная

Что такое *очень_важная_витрина* по Кимбаллу?

- таблица фактов
- агрегированная
- консолидированная

Глобально по Кимбаллу есть два вида таблиц:

- измерений
- фактов

Факты: числа/события

Измерения: текст/описательный контекст

Что такое *очень_важная_витрина* по Кимбаллу?

- таблица фактов
- агрегированная
- консолидированная

Глобально по Кимбаллу есть два вида таблиц:

- измерений
- фактов

Факты: числа/события

Измерения: текст/описательный контекст

«Агрегированные таблицы фактов – простые числовые свёртки данных атомарной таблицы фактов, созданные исключительно для повышения производительности запросов.

Эти сводные таблицы фактов должны быть доступны для уровня бизнес-аналитики одновременно с атомарными таблицами фактов».

Что такое *очень_важная_витрина* по Кимбаллу?

- таблица фактов
- агрегированная
- консолидированная

Глобально по Кимбаллу есть два вида таблиц:

- измерений
- фактов

Факты: числа/события

Измерения: текст/описательный контекст

«Агрегированные таблицы фактов – простые числовые свёртки данных атомарной таблицы фактов, созданные исключительно для повышения производительности запросов.

Эти сводные таблицы фактов должны быть доступны для уровня бизнес-аналитики одновременно с атомарными таблицами фактов».

«Таблицы фактов, которые объединяют показатели из нескольких бизнес-процессов с общей степенью детализации, называются консолидированными таблицами фактов».

Что такое *очень_важная_витрина* по Кимбаллу?

Обратим внимание:

«Агрегированные таблицы фактов – *простые числовые свёртки* данных атомарной таблицы фактов, *созданные исключительно для повышения производительности запросов.*»

Эти сводные таблицы фактов должны быть доступны для уровня бизнес-аналитики одновременно с атомарными таблицами фактов».

Что такое *очень_важная_витрина* по Кимбаллу?

Обратим внимание:

«Агрегированные таблицы фактов – *простые числовые свёртки* данных атомарной таблицы фактов, *созданные исключительно для повышения производительности запросов.*»

Эти сводные таблицы фактов должны быть доступны для уровня бизнес-аналитики одновременно с атомарными таблицами фактов».

... но у нас не такие уж простые, а со своими «внутренними наворотами»

Что такое *очень_важная_витрина* по Кимбаллу?

Обратим внимание:

«Агрегированные таблицы фактов – *простые числовые свёртки* данных атомарной таблицы фактов, *созданные исключительно для повышения производительности запросов.*»

Эти сводные таблицы фактов должны быть доступны для уровня бизнес-аналитики одновременно с атомарными таблицами фактов».

«Таблицы фактов, которые *объединяют показатели из нескольких бизнес-процессов* с общей степенью детализации, называются консолидированными таблицами фактов».

... но у нас не такие уж простые, а со своими «внутренними наворотами»

Что такое *очень_важная_витрина* по Кимбаллу?

Обратим внимание:

«Агрегированные таблицы фактов – *простые числовые свёртки* данных атомарной таблицы фактов, *созданные исключительно для повышения производительности запросов.*»

Эти сводные таблицы фактов должны быть доступны для уровня бизнес-аналитики одновременно с атомарными таблицами фактов».

«Таблицы фактов, которые *объединяют показатели из нескольких бизнес-процессов* с общей степенью детализации, называются консолидированными таблицами фактов».

... но у нас не такие уж простые, а со своими «внутренними наворотами»

... за счёт чего объединяют?

Что внутри?

За счёт чего *объединяются показатели из нескольких бизнес-процессов*

Что внутри?


За счёт чего *объединяются показатели из нескольких бизнес-процессов*

и почему *простые числовые свёртки*

Что внутри?

За счёт чего *объединяются показатели из нескольких бизнес-процессов*

и почему *простые числовые свёртки*




Эти два вопроса связаны:

Эти два вопроса связаны:

часть *«внутренних наворотов»* решает задачу *объединения показателей из нескольких бизнес-процессов*


Эти два вопроса связаны:

часть *«внутренних наворотов»* решает задачу *объединения показателей из нескольких бизнес-процессов*



Эти два вопроса связаны:

часть *«внутренних наворотов»* решает задачу *объединения показателей из нескольких бизнес-процессов*



Как именно происходит *объединение показателей из нескольких бизнес-процессов?*

Внутри *очень_важная_витрина* есть раздел *важный_раздел*

Как именно происходит *объединение показателей из нескольких бизнес-процессов?*

Внутри *очень_важная_витрина* есть раздел *важный_раздел*
(в будущем планируется переход на отдельный объект – *отдельный_объект*).

Как именно происходит *объединение показателей из нескольких бизнес-процессов?*

Внутри *очень_важная_витрина* есть раздел *важный_раздел*
(в будущем планируется переход на отдельный объект – *отдельный_объект*).

Этот раздел выступает в качестве «скелета», на который мы далее нанизываем/собираем фактические данные.

Как именно происходит *объединение показателей из нескольких бизнес-процессов?*

Внутри *очень_важная_витрина* есть раздел *важный_раздел*
(в будущем планируется переход на отдельный объект – *отдельный_объект*).

Этот раздел выступает в качестве «скелета», на который мы далее нанизываем/собираем фактические данные.

Этот раздел состоит из ряда полей:

Как именно происходит *объединение показателей из нескольких бизнес-процессов?*

Внутри *очень_важная_витрина* есть раздел *важный_раздел*
(в будущем планируется переход на отдельный объект – *отдельный_объект*).

Этот раздел выступает в качестве «скелета», на который мы далее нанизываем/собираем фактические данные.

Этот раздел состоит из ряда полей:

- user_id
- profile_id
- no_auth_id
- profile_type
- ...

Как именно происходит *объединение показателей из нескольких бизнес-процессов?*

Внутри *очень_важная_витрина* есть раздел *важный_раздел*
(в будущем планируется переход на отдельный объект – *отдельный_объект*).

Этот раздел выступает в качестве «скелета», на который мы далее нанизываем/собираем фактические данные.

Этот раздел состоит из ряда полей:

- user_id
 - profile_id
 - no_auth_id
 - profile_type
 - ...
- device_id
 - device_type
 - ...

Как именно происходит *объединение показателей из нескольких бизнес-процессов?*

Внутри *очень_важная_витрина* есть раздел *важный_раздел*
(в будущем планируется переход на отдельный объект – *отдельный_объект*).

Этот раздел выступает в качестве «скелета», на который мы далее нанизываем/собираем фактические данные.

Этот раздел состоит из ряда полей:

- user_id
 - profile_id
 - no_auth_id
 - profile_type
 - ...
- device_id
 - device_type
 - ...

Поля относятся к двум бизнес-сущностям:

Как именно происходит *объединение показателей из нескольких бизнес-процессов?*

Внутри *очень_важная_витрина* есть раздел *важный_раздел*
(в будущем планируется переход на отдельный объект – *отдельный_объект*).

Этот раздел выступает в качестве «скелета», на который мы далее нанизываем/собираем фактические данные.

Этот раздел состоит из ряда полей:

- user_id
 - profile_id
 - no_auth_id
 - profile_type
 - ...
- device_id
 - device_type
 - ...

Поля относятся к двум бизнес-сущностям:

- пользователь
- устройство

Задача со звёздочкой

Что это за таблица *важный_раздел / отдельный_объект*?

Что это за таблица *по Кимбаллу*?



важный_раздел / отдельный_объект:

logical_dt	user_id	profile_id	no_auth_id	device_id	app_platform
2026-01-01	11111	11111-01		abra-01-cad	tv
2026-01-01	22222	22222-01		cada-02-bra	tv
2026-01-01	33333	33333-01		cadabra-01%	web
...					
2026-01-02	11111	11111-01		abra-01-cad	tv
2026-01-02	22222	22222-01		cada-02-bra	tv
2026-01-02	33333	33333-02		cadabra-01%	web
...					
2026-01-03	11111	11111-01		abra-01-cad	tv
2026-01-03	22222	22222-02		cada-02-bra	tv
2026-01-03	33333	33333-01		cadabra-01%	web
...	...	...	...	...	...



Что за таблица *важный_раздел / отдельный_объект*
по Кимбаллу?

A: таблица фактов без фактов

B:

C:

D:



Что за таблица *важный_раздел / отдельный_объект*
по Кимбаллу?

А: таблица фактов без фактов

В: таблица измерений без измерений

С:

Д:



Что за таблица *важный_раздел / отдельный_объект*
по Кимбаллу?

А: таблица фактов без фактов

В: таблица измерений без измерений

С: таблица-мост

Д:



Что за таблица *важный_раздел / отдельный_объект*
по Кимбаллу?

A: таблица фактов без фактов

B: таблица измерений без измерений

C: таблица-мост

D: календарная таблица учёта



Что за таблица *важный_раздел / отдельный_объект*
по Кимбаллу?

A: таблица фактов без фактов

B: таблица измерений без измерений

C: таблица-мост

D: календарная таблица учёта

Выводы



Что хорошо

Получается, внутри *очень_важная_витрина* за счёт таблицы фактов без фактов мы соединяем данные из разных бизнес-процессов, т.е. *консолидируем* их.

Что хорошо

Получается, внутри *очень_важная_витрина* за счёт таблицы фактов без фактов мы соединяем данные из разных бизнес-процессов, т.е. *консолидируем* их.

Чтобы данные поджойнились (=консолидировались), мы делаем на этом шаге *согласованные измерения*.

Что хорошо

Получается, внутри *очень_важная_витрина* за счёт таблицы фактов без фактов мы соединяем данные из разных бизнес-процессов, т.е. *консолидируем* их.

Чтобы данные поджойнились (=консолидировались), мы делаем на этом шаге *согласованные измерения*.

Согласованные измерения состоят из ряда полей:

Что хорошо

Получается, внутри *очень_важная_витрина* за счёт таблицы фактов без фактов мы соединяем данные из разных бизнес-процессов, т.е. *консолидируем* их.

Чтобы данные поджойнились (=консолидировались), мы делаем на этом шаге *согласованные измерения*.

Согласованные измерения состоят из ряда полей:

- user_id
- profile_id
- no_auth_id
- profile_type
- ...

Что хорошо

Получается, внутри *очень_важная_витрина* за счёт таблицы фактов без фактов мы соединяем данные из разных бизнес-процессов, т.е. *консолидируем* их.

Чтобы данные поджойнились (=консолидировались), мы делаем на этом шаге *согласованные измерения*.

Согласованные измерения состоят из ряда полей:

- user_id
 - profile_id
 - no_auth_id
 - profile_type
 - ...
- device_id
 - device_type
 - ...

Что хорошо

Получается, внутри *очень_важная_витрина* за счёт таблицы фактов без фактов мы соединяем данные из разных бизнес-процессов, т.е. **консолидируем** их.

Чтобы данные поджойнились (=консолидировались), мы делаем на этом шаге **согласованные измерения**.

Согласованные измерения состоят из ряда полей:

- user_id
- profile_id
- no_auth_id
- profile_type
- ...
- device_id
- device_type
- ...

Согласованные измерения относятся к двум бизнес-сущностям:

Что хорошо

Получается, внутри *очень_важная_витрина* за счёт таблицы фактов без фактов мы соединяем данные из разных бизнес-процессов, т.е. **консолидируем** их.

Чтобы данные поджойнились (=консолидировались), мы делаем на этом шаге **согласованные измерения**.

Согласованные измерения состоят из ряда полей:

- user_id
- profile_id
- no_auth_id
- profile_type
- ...
- device_id
- device_type
- ...

Согласованные измерения относятся к двум бизнес-сущностям:

- пользователь
- устройство

Что хорошо

Это хорошо, что у нас в *очень_важная_витрина* есть согласованные измерения: благодаря этому мы консолидируем данные (визиты/селекты/просмотры).

По Кимбаллу согласованные измерения – одна из главных «фишек» его методологии.

Что хорошо

Это хорошо, что у нас в *очень_важная_витрина* есть согласованные измерения: благодаря этому мы консолидируем данные (визиты/селекты/просмотры).

По Кимбаллу согласованные измерения – одна из главных «фишек» его методологии.

Согласованные измерения помогают исследовать данные в хранилище:

- и вглубь (drill-down),
- и вдоль (drill across).



Что плохо (проблемы/зоны роста)

Но если мы попробуем исследовать данные из *очень_важная_витрина*

- *вглубь (drill-down)*

Что плохо (проблемы/зоны роста)

Но если мы попробуем исследовать данные из *очень_важная_витрина*

- *вглубь (drill-down)*

то есть, например, из агрегированной строки:

user_id	profile_id	device_id	...	watched_time_ss
111	111-000-0000001	TV111		900

Что плохо (проблемы/зоны роста)

Но если мы попробуем исследовать данные из *очень_важная_витрина*

- *вглубь (drill-down)*

то есть, например, из агрегированной строки:

user_id	profile_id	device_id	...	watched_time_ss
111	111-000-00000001	TV111		900

захотим получить информацию более детальную (что именно смотрел пользователь):

Что плохо (проблемы/зоны роста)

Но если мы попробуем исследовать данные из *очень_важная_витрина*

- *вглубь (drill-down)*

то есть, например, из агрегированной строки:

user_id	profile_id	device_id	...	watched_time_ss
111	111-000-0000001	TV111		900

захотим получить информацию более детальную (что именно смотрел пользователь):

user_id	profile_id	device_id	...	content_name	watched_time_ss
111	111-000-0000001	TV111		Три Кота. Серия 1	300
111	111-000-0000001	TV111		Три Кота. Серия 2	300
111	111-000-0000001	TV111		Три Кота. Серия 3	300

Мы не всегда сможем это сделать без «шероховатостей».

Мы не всегда сможем это сделать без «шероховатостей».

Потому что мы внутри *очень_важная_витрина* имеем много «сакрального» знания:

Мы не всегда сможем это сделать без «шероховатостей».

Потому что мы внутри *очень_важная_витрина* имеем много «сакрального» знания:

- «добираем» user_id из неавторизованной зоны
- используем «смердженого» user_id
- «догенерируем» profile_id (если его нет) из user_id
- no_auth_id зануляем, если пользователь авторизовался

Мы не всегда сможем это сделать без «шероховатостей».

Потому что мы внутри *очень_важная_витрина* имеем много «сакрального» знания:

- «добираем» user_id из неавторизованной зоны
- используем «смердженого» user_id
- «догенерируем» profile_id (если его нет) из user_id
- no_auth_id зануляем, если пользователь авторизовался

То есть не во всех случаях мы можем *просто так взять и прийти в источник* и получить нужные детальные данные.

Мы не всегда сможем это сделать без «шероховатостей».

Потому что мы внутри *очень_важная_витрина* имеем много «сакрального» знания:

- «добираем» user_id из неавторизованной зоны
- используем «смердженого» user_id
- «догенерируем» profile_id (если его нет) из user_id
- no_auth_id зануляем, если пользователь авторизовался

То есть не во всех случаях мы можем *просто так взять и прийти в источник* и получить нужные детальные данные.



Что плохо (проблемы/зоны роста)

Если мы попробуем исследовать данные из *очень_важная_витрина*

- *вдоль (drill across)*

Что плохо (проблемы/зоны роста)

Если мы попробуем исследовать данные из *очень_важная_витрина*

- *вдоль (drill across)*

то есть, например, из строки:

user_id	profile_id	device_id	...	watched_time_ss
111	111-000-0000001	TV111		900

Что плохо (проблемы/зоны роста)

Если мы попробуем исследовать данные из *очень_важная_витрина*

- *вдоль (drill across)*

то есть, например, из строки:

user_id	profile_id	device_id	...	watched_time_ss
111	111-000-00000001	TV111		900

захотим получить информацию о пользователе из другой бизнес-области (например, оплата, подписка):

Что плохо (проблемы/зоны роста)

Если мы попробуем исследовать данные из *очень_важная_витрина*

- *вдоль (drill across)*

то есть, например, из строки:

user_id	profile_id	device_id	...	watched_time_ss
111	111-000-0000001	TV111		900

захотим получить информацию о пользователе из другой бизнес-области (например, оплата, подписка):

user_id	profile_id	device_id	...	subscription_type
111	111-000-0000001	TV111		XXX

Что плохо (проблемы/зоны роста)

Если мы попробуем исследовать данные из *очень_важная_витрина*

- *вдоль (drill across)*

то есть, например, из строки:

user_id	profile_id	device_id	...	watched_time_ss
111	111-000-0000001	TV111		900

захотим получить информацию о пользователе из другой бизнес-области (например, оплата, подписка):

user_id	profile_id	device_id	...	subscription_type
111	111-000-0000001	TV111		XXX

Мы не всегда сможем это сделать без «шероховатостей».



Ведь чтобы не испытывать «шероховатостей» и
просто так взять и прийти
в источник/смежную область,



Ведь чтобы не испытывать «шероховатостей» и
просто так взять и прийти
в источник/смежную область,

нам нужны



Ведь чтобы не испытывать «шероховатостей» и
просто так взять и прийти
в источник/смежную область,

нам нужны

согласованные измерения



Ведь чтобы не испытывать «шероховатостей» и
просто так взять и прийти
в источник/смежную область,

нам нужны

согласованные измерения



по всему хранилищу данных



Иными словами, почитав теорию, мы можем понять – улучшение *очень_важная_витрина* состоит в:

1. упрощении *очень_важная_витрина* /улучшении Хранилища

- «внутренние навороты»/«сакральное знание» однажды должны перестать быть таковыми: нужно, чтобы всё это было доступно в источниках (например, в слое datamarts)
- *очень_важная_витрина* должна быть похожа на «простой числовой свёрток»

2. применение/адаптация идей согласованности внутри *очень_важная_витрина*

- идеи «согласованных измерений», «согласованных фактов» из методологии Кимбалла можно применить относительно сущностей внутри *очень_важная_витрина*. Например, можно сделать «согласованные флаги»

Выводы

Итак, что мы узнали

очень_важная_витрина по Кимбаллу – это:

- таблица фактов
- агрегированная
- консолидированная

Что хорошо:

- она справляется со своей задачей - консолидирует данные из разных бизнес-процессов

Что плохо:

- имеет ряд внутренних «наворотов»/«сакрального знания», хотя в идеале не должна их иметь
- при попытках исследования данных вглубь и вдоль/сопоставления с источниками могут быть «шероховатости»

Выводы

Идеи:

- есть идея на глобальное будущее – вывести «внутренние навороты»/ «сакральное знание» на уровень источников *очень_важная_внутрина* (слой datamarts)
- есть идея более узкая и прикладная – применить идею из методологии Кимбалла на внутренний лад – сделать согласованные флаги


Выводы

Ещё одна идея – продолжить подобные разборы

Например, можно разобрать основные идеи и «фишки» методологии Кимбалла или сравнить методологии между собой

Выводы

Об этом и многом другом можно прочитать здесь:



Спасибо
за внимание

