

Теория и практика DWH:

основные идеи Кимбалла

часть 1

Что обсудим:

- Вступление:
 - что такое теория и практика DWH, зачем это нужно
 - кто такой Кимбалл, его книги
- Основная часть:
 - основные идеи Кимбалла
 - таблицы фактов
 - таблицы измерений
 - согласованные факты
 - согласованные измерения
 - основные ценности подхода
- Источники

Вступление



Что такое теория и практика DWH, зачем это нужно?

Представим себя в компьютерной игре.


Если у нас есть что-то одно (только теория или только практика), мы видим:



Если есть и теория, и практика, мы расширяем/дополняем свой обзор:



Если есть и теория, и практика, мы расширяем/дополняем свой обзор:



Сегодня мы расширим/дополним свой обзор на тему:

Кимбалл

и

Сегодня мы расширим/дополним свой обзор на тему:

Кимбалл

и


его основные идеи

Кто такой Кимбалл?

Ральф Кимбалл - автор методологии размерного моделирования (dimensional modeling), которая стала одной из двух основных подходов к проектированию хранилищ данных.





Основной его труд – это книга «The Data Warehouse Toolkit»



В переводе эта книга выглядит так:



Здесь и далее, говоря «Кимбалл», будем иметь ввиду его подход:



Основная часть



Основные идеи Кимбалла

Если кратко, основные идеи размерного моделирования:

1. таблицы фактов (события/числа)
2. таблицы измерений (описательный контекст)
3. четырёхэтапный процесс размерного проектирования
4. шина, матрица шины корпоративного хранилища данных
5. согласованные факты
6. согласованные измерения
7. суррогатные ключи
8. 8 типов SCD (атрибуты медленно меняющихся измерений)
9. типичные ошибки
10. основные ценности подхода

Основные идеи Кимбалла

Если кратко, основные идеи размерного моделирования:

1. таблицы фактов (события/числа)
2. таблицы измерений (описательный контекст)
3. четырёхэтапный процесс размерного проектирования
4. шина, матрица шины корпоративного хранилища данных
5. согласованные факты
6. согласованные измерения
7. суррогатные ключи
8. 8 типов SCD (атрибуты медленно меняющихся измерений)
9. типичные ошибки
10. основные ценности подхода



Основные идеи Кимбалла

Если кратко, основные идеи размерного моделирования:

1. **таблицы фактов (события/числа)**
2. **таблицы измерений (описательный контекст)**
3. четырёхэтапный процесс размерного проектирования
4. шина, матрица шины корпоративного хранилища данных
5. **согласованные факты**
6. **согласованные измерения**
7. суррогатные ключи
8. 8 типов SCD (атрибуты медленно меняющихся измерений)
9. типичные ошибки
10. **основные ценности подхода**



таблицы в размерном моделировании

глобально делятся на 2 типа:

факты	измерения
-------	-----------

таблицы фактов (события/числа)

факты
события
числа

таблицы фактов (события/числа)

факты
события
числа
глаголы действий

таблицы фактов (события/числа)

факты
события
числа
глаголы действий
то, что агрегируем

таблицы фактов (события/числа)

факты
события
числа
глаголы действий
то, что агрегируем
узкие и длинные

таблицы фактов (события/числа)

факты
события
числа
глаголы действий
то, что агрегируем
узкие и длинные
null оставляем

таблицы измерений (описательный контекст)

измерения
описательный контекст
текст

таблицы измерений (описательный контекст)

измерения
описательный контекст
текст
«кто, что, где, когда, почему и как», окружающие событие

таблицы измерений (описательный контекст)

измерения
описательный контекст
текст
«кто, что, где, когда, почему и как», окружающие событие
фильтрация и группировка

таблицы измерений (описательный контекст)

измерения
описательный контекст
текст
«кто, что, где, когда, почему и как», окружающие событие
фильтрация и группировка
широкие и короткие

таблицы измерений (описательный контекст)

измерения
описательный контекст
текст
«кто, что, где, когда, почему и как», окружающие событие
фильтрация и группировка
широкие и короткие
null заменяем описательной строкой (например, 'undefined')

таблицы фактов vs таблицы измерений

факты	измерения
события	описательный контекст
числа	текст
глаголы действий	«кто, что, где, когда, почему и как», окружающие событие
то, что агрегируем	фильтрация и группировка
узкие и длинные	широкие и короткие
null оставляем	null заменяем описательной строкой (например, 'undefined')

согласованные факты

Если одни и те же факты отображаются в нескольких таблицах фактов, [...], то они должны иметь согласованные определения и метки.

Если факты не идентичны, то им нужно дать разные названия»

глава 16, стр. 474

согласованные факты

Если одни и те же факты отображаются в нескольких таблицах фактов, [...], то они должны иметь согласованные определения и метки.

Если факты не идентичны, то им нужно дать разные названия»

глава 16, стр. 474

«Если у вас есть числовой измеряемый факт, такой как доход, в двух или более базах данных, полученных из разных базовых систем, вам необходимо проявлять особую осторожность, чтобы убедиться, что технические определения этих фактов точно совпадают.

Если определения не совсем совпадают, то их не следует называть доходом. Это согласование фактов»

глава 16, стр. 490

согласованные факты

Одни и те же бизнес-события – в разных местах – имеют:

- одинаковое наименование
- одинаковое определение

Например, в магазине выручка не называлась бы:

- revenue,
- sales,
- rev,
- sales_amount,
- rub_amount,
- [...]

А везде называлась бы одним способом, например, revenue.

согласованные факты

В онлайн-кинотеатре это могло бы быть одинаковое определение, например, времени просмотра. Вместо разных:

- watched_time,
- play_duration_sec,
- wt,
- [...]

для одинакового факта было бы одно название.

согласованные факты

В онлайн-кинотеатре это могло бы быть одинаковое определение, например, времени просмотра. Вместо разных:

- watched_time,
- play_duration_sec,
- wt,
- [...]


для одинакового факта было бы одно название.

А если в двух витринах расчёт факта/определение факта отличается, то и названия должны быть разными.

Например:

- watched_time
- watched_time_without_broken_heartbeats

лирическое отступление



хорошо то хранилище, которым пользуются

Деловое сообщество должно принять систему DW/BI, чтобы считать её успешной. Неважно, что вы создали элегантное решение, используя лучшие в своём роде продукты и платформы. Если бизнес-сообщество не принимает эту DW/BI-среду и не использует её активно, вы не прошли вступительный тест

глава 1, стр.37

Успех DW/BI напрямую связан с признанием бизнеса. Если пользователи не приняли систему DW/BI в качестве основы для улучшения процесса принятия решений, ваши усилия оказались тщетными

глава 17, стр. 521

«душа» хранилища - измерения

Таблицы измерений иногда называют «душой» хранилища данных

глава 2, стр. 77

Во многих отношениях хранилища данных настолько хороши,
насколько хороши атрибуты измерения

глава 1, стр. 48

согласованные измерения

Одним из значительных успехов подхода к размерному моделированию стало определение простого, но действенного рецепта интеграции данных из различных бизнес-процессов.

Таблицы измерений согласованы, когда у атрибутов в отдельных таблицах измерений одинаковые имена столбцов и содержимое домена

глава 2, стр. 90-91

согласованные измерения

Одним из значительных успехов подхода к размерному моделированию стало определение простого, но действенного рецепта интеграции данных из различных бизнес-процессов.

Таблицы измерений согласованы, когда у атрибутов в отдельных таблицах измерений одинаковые имена столбцов и содержимое домена

глава 2, стр. 90-91

стандартизированные согласованные измерения [...] служат краеугольным камнем шины [корпоративного хранилища данных], поскольку они используются в таблицах фактов бизнес-процессов

глава 4, стр. 185

согласованные измерения

Один и тот же описательный контекст бизнес-событий – в разных местах – имеет:

- одинаковое наименование
- одинаковое определение
- связан с разными таблицами фактов

согласованные измерения

Один и тот же описательный контекст бизнес-событий – в разных местах – имеет:

- одинаковое наименование
- одинаковое определение
- связан с разными таблицами фактов

Например, в магазине покупатель не назывался бы:

- customer_id,
- client_id,
- user_id,
- shop_client_id,
- [...]

согласованные измерения

Один и тот же описательный контекст бизнес-событий – в разных местах – имеет:

- одинаковое наименование
- одинаковое определение
- связан с разными таблицами фактов

Например, в магазине покупатель не назывался бы:

- customer_id,
- client_id,
- user_id,
- shop_client_id,
- [...]

А везде назывался бы одним способом, например, customer_id;
и это значение использовалось в разных таблицах фактов, например,
в таблице заказов, в таблице с адресом доставки и т.д.

согласованные измерения

В онлайн-кинотеатре это могло бы быть одинаковое определение, например, того же пользователя/клиента и/или его профиля. Вместо разных:

согласованные измерения

В онлайн-кинотеатре это могло бы быть одинаковое определение, например, того же пользователя/клиента и/или его профиля. Вместо разных:

- user_id,
- merged_user_id,
- userid,
- [...]

согласованные измерения

В онлайн-кинотеатре это могло бы быть одинаковое определение, например, того же пользователя/клиента и/или его профиля. Вместо разных:

- user_id,
 - merged_user_id,
 - userid,
 - [...]
-
- profile_id,
 - multiprofile_uid,
 - [...]

согласованные измерения

В онлайн-кинотеатре это могло бы быть одинаковое определение, например, того же пользователя/клиента и/или его профиля. Вместо разных:

- user_id,
- merged_user_id,
- userid,
- [...]

- profile_id,
- multiprofile_uid,
- [...]

для одинакового определения пользователя/профиля было бы одно название.

согласованные измерения

В онлайн-кинотеатре это могло бы быть одинаковое определение, например, того же пользователя/клиента и/или его профиля. Вместо разных:

- user_id,
 - merged_user_id,
 - userid,
 - [...]
-
- profile_id,
 - multiprofile_uid,
 - [...]

для одинакового определения пользователя/профиля было бы одно название.

А если в двух витринах определение пользователя отличается, то и названия должны быть разными. Например:

- user_id
- merged_user_id

согласованные измерения


Как технически организовываются согласованные измерения – описано в главе 19, можно выделить в частности:

- подсистема 8: согласующая система стр. 560-562
- подсистема 14: конвейер суррогатных ключей стр. 576-578
- подсистема 17: система управления измерениями стр.580-581
- подсистема 18: система предоставления фактов стр.581-582


согласованные измерения - кратко




согласованные измерения - кратко




согласованные измерения - кратко



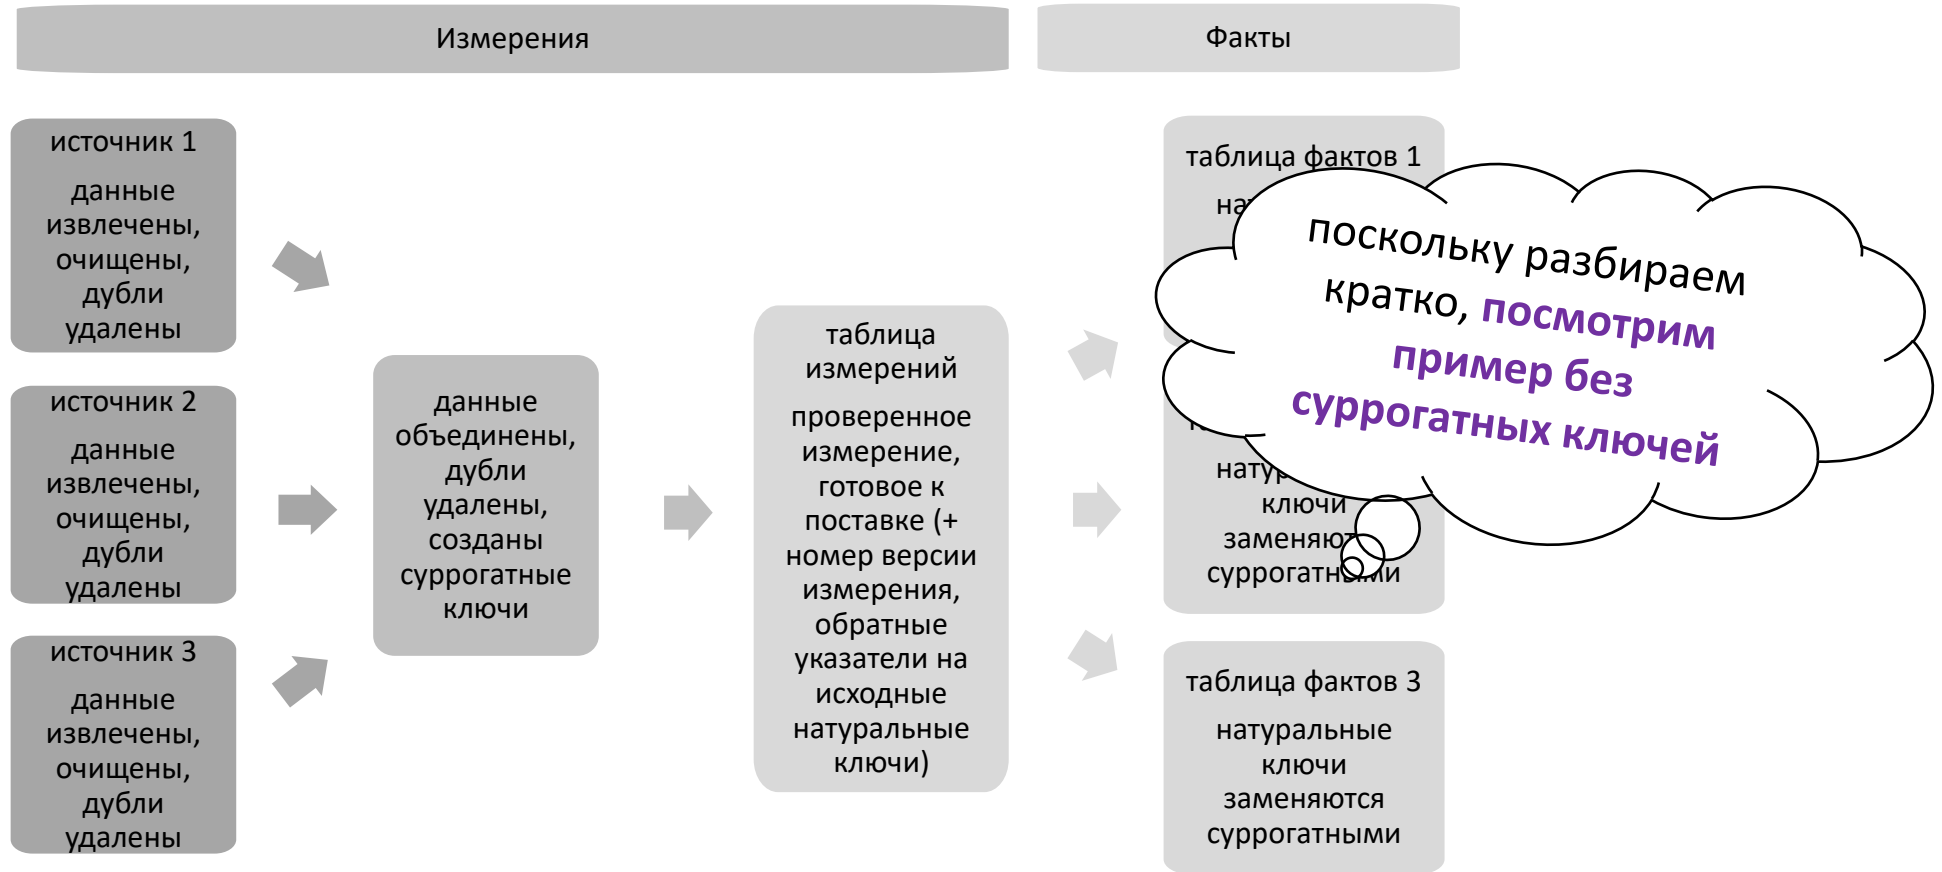
согласованные измерения - кратко




согласованные измерения - кратко



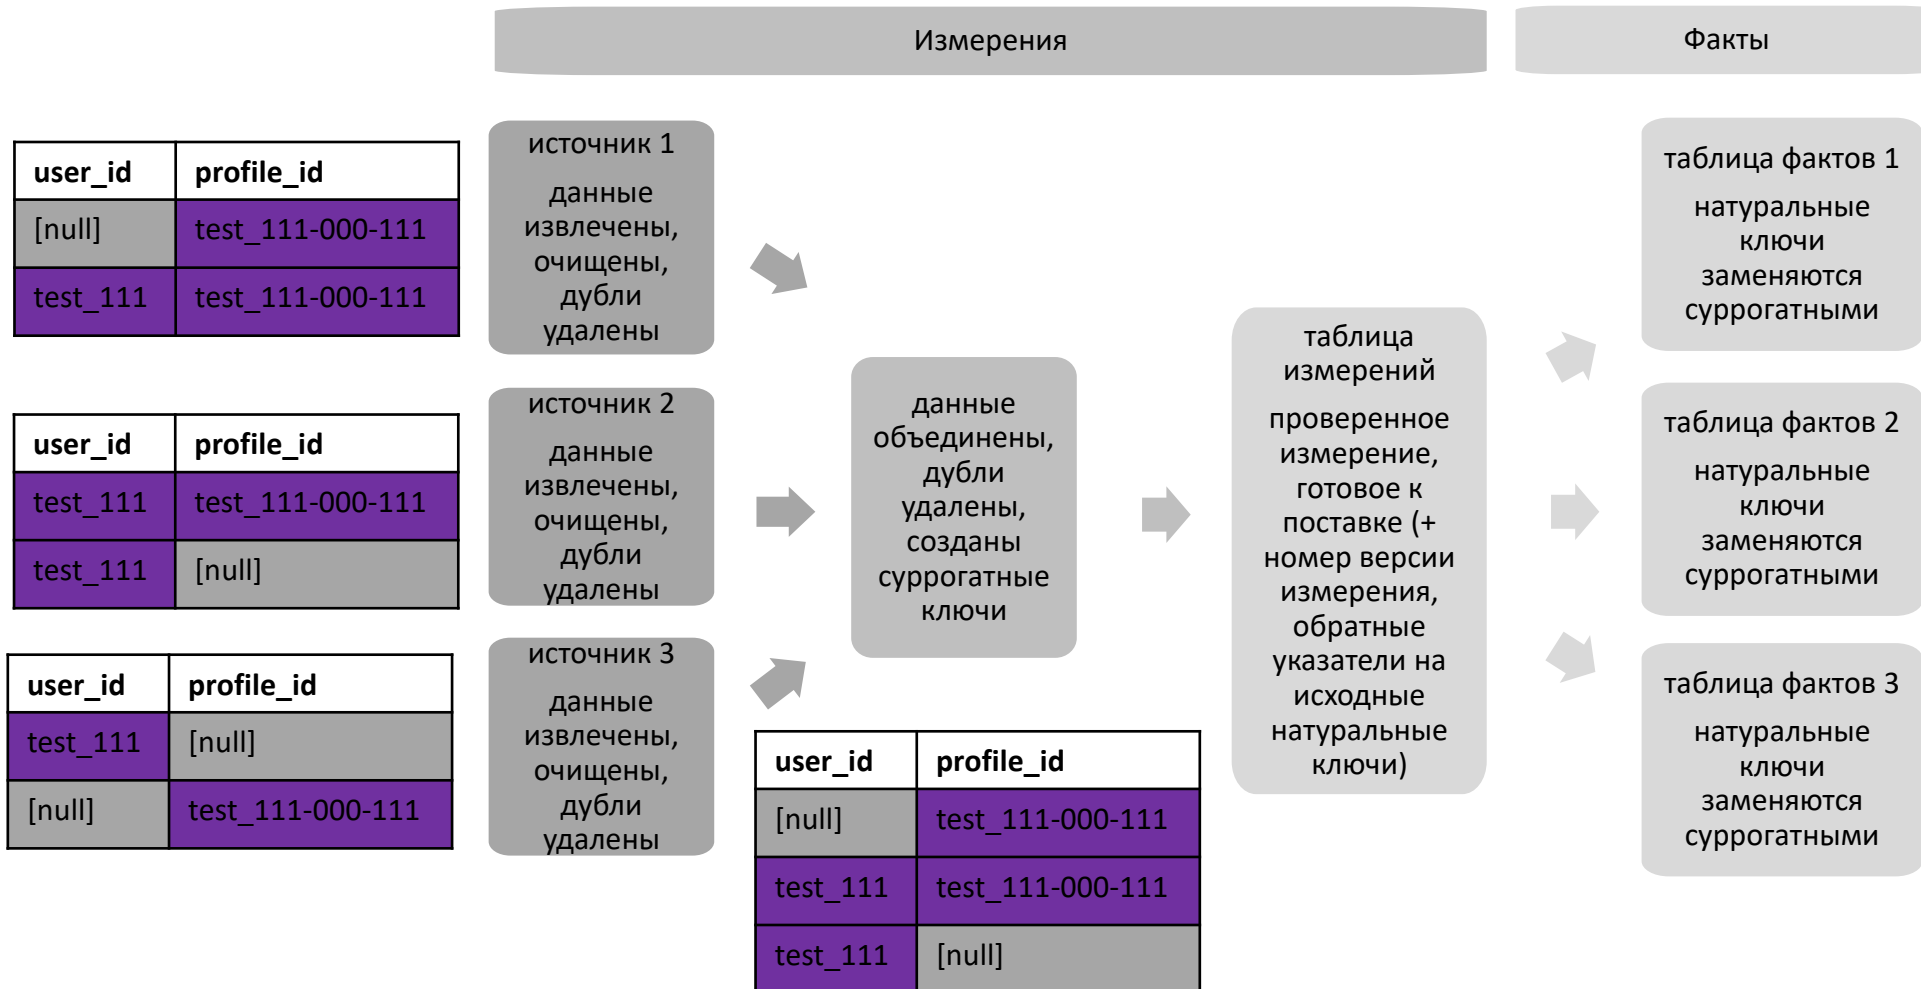
согласованные измерения - кратко



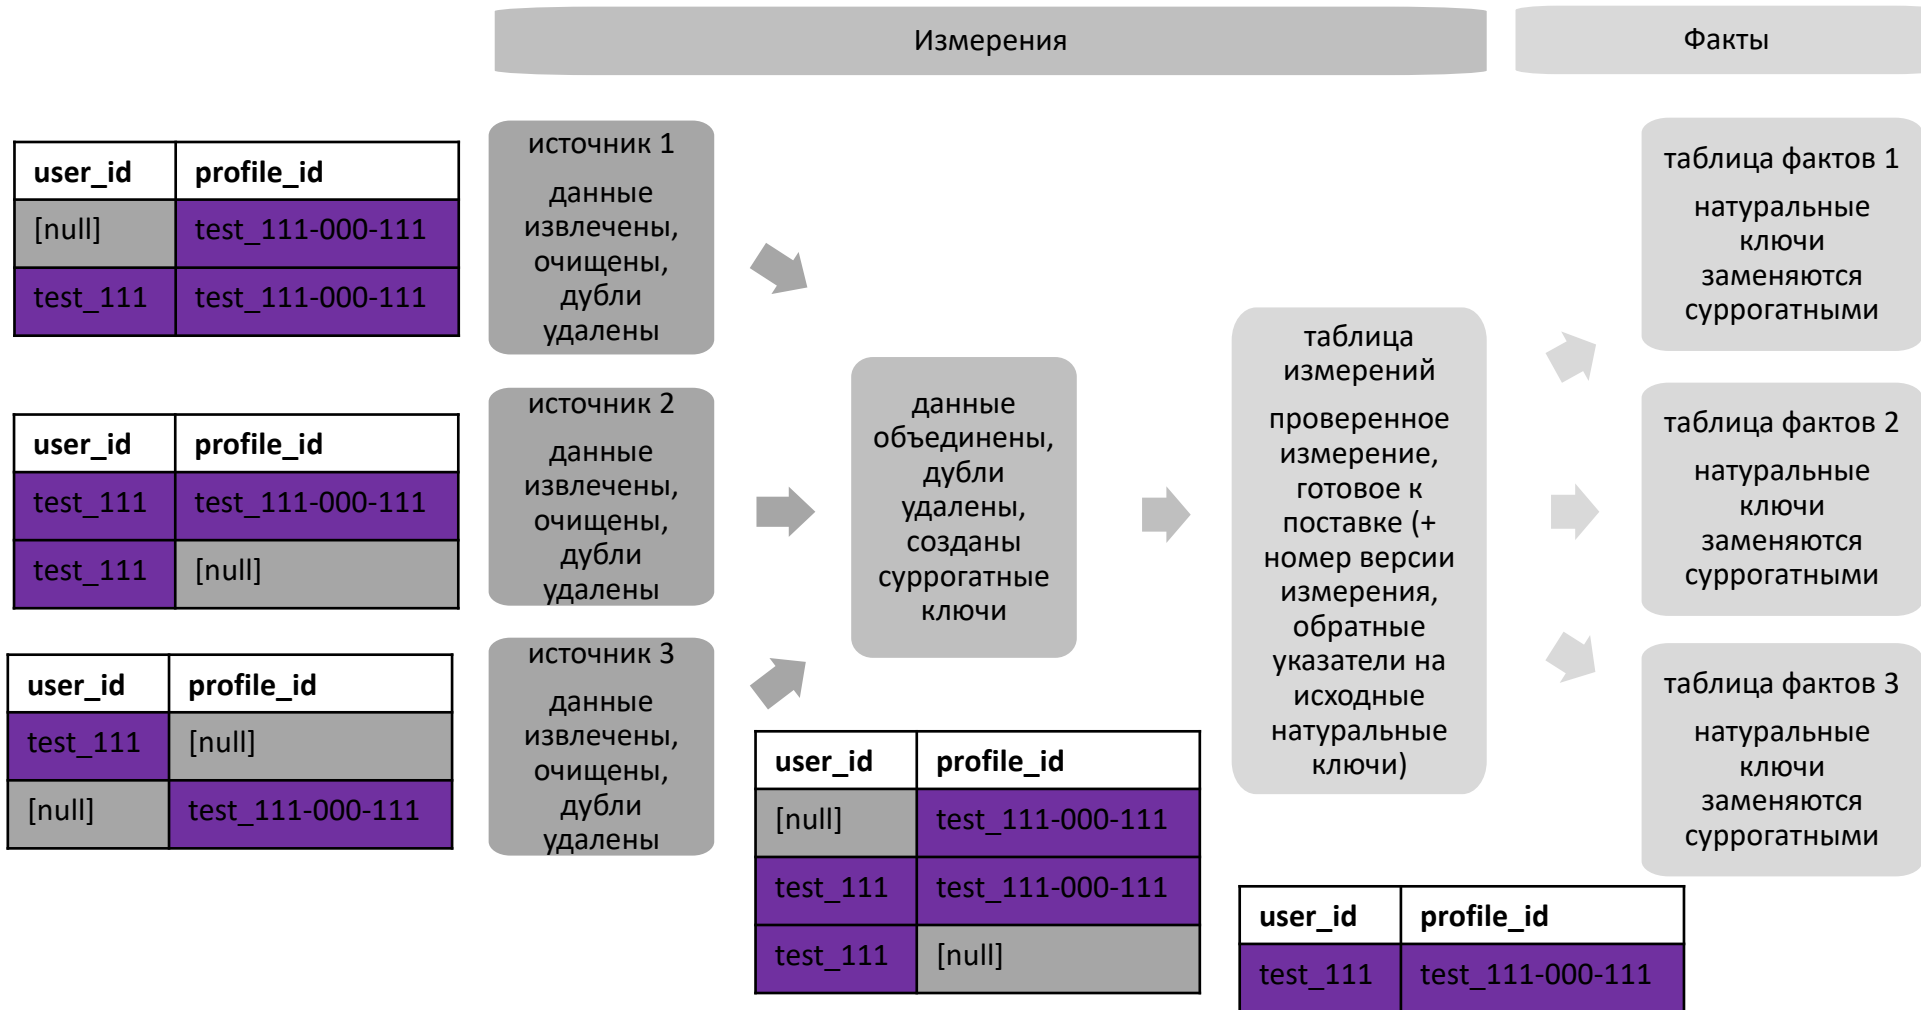
согласованные измерения - кратко



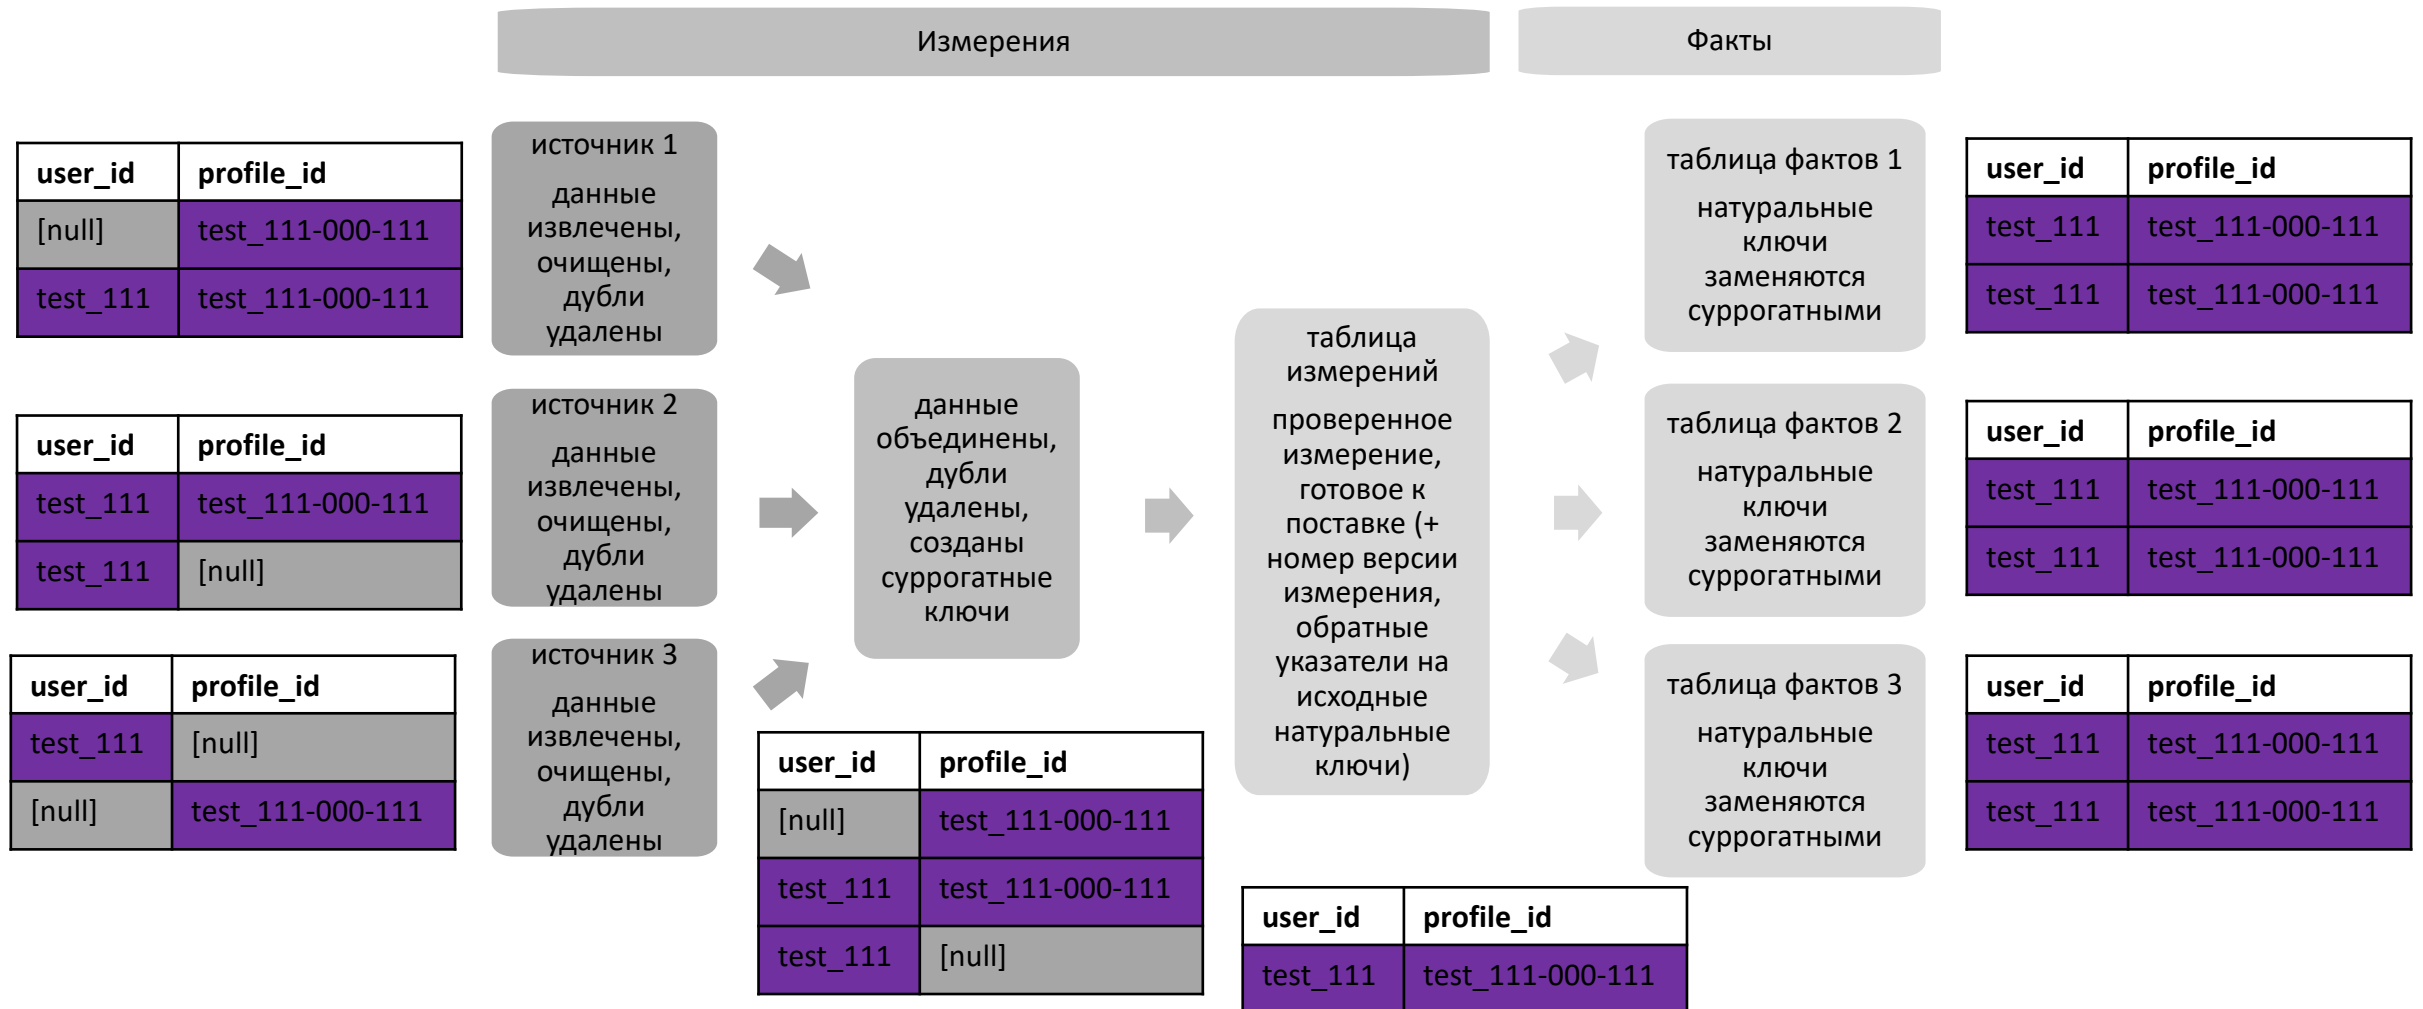
согласованные измерения - кратко



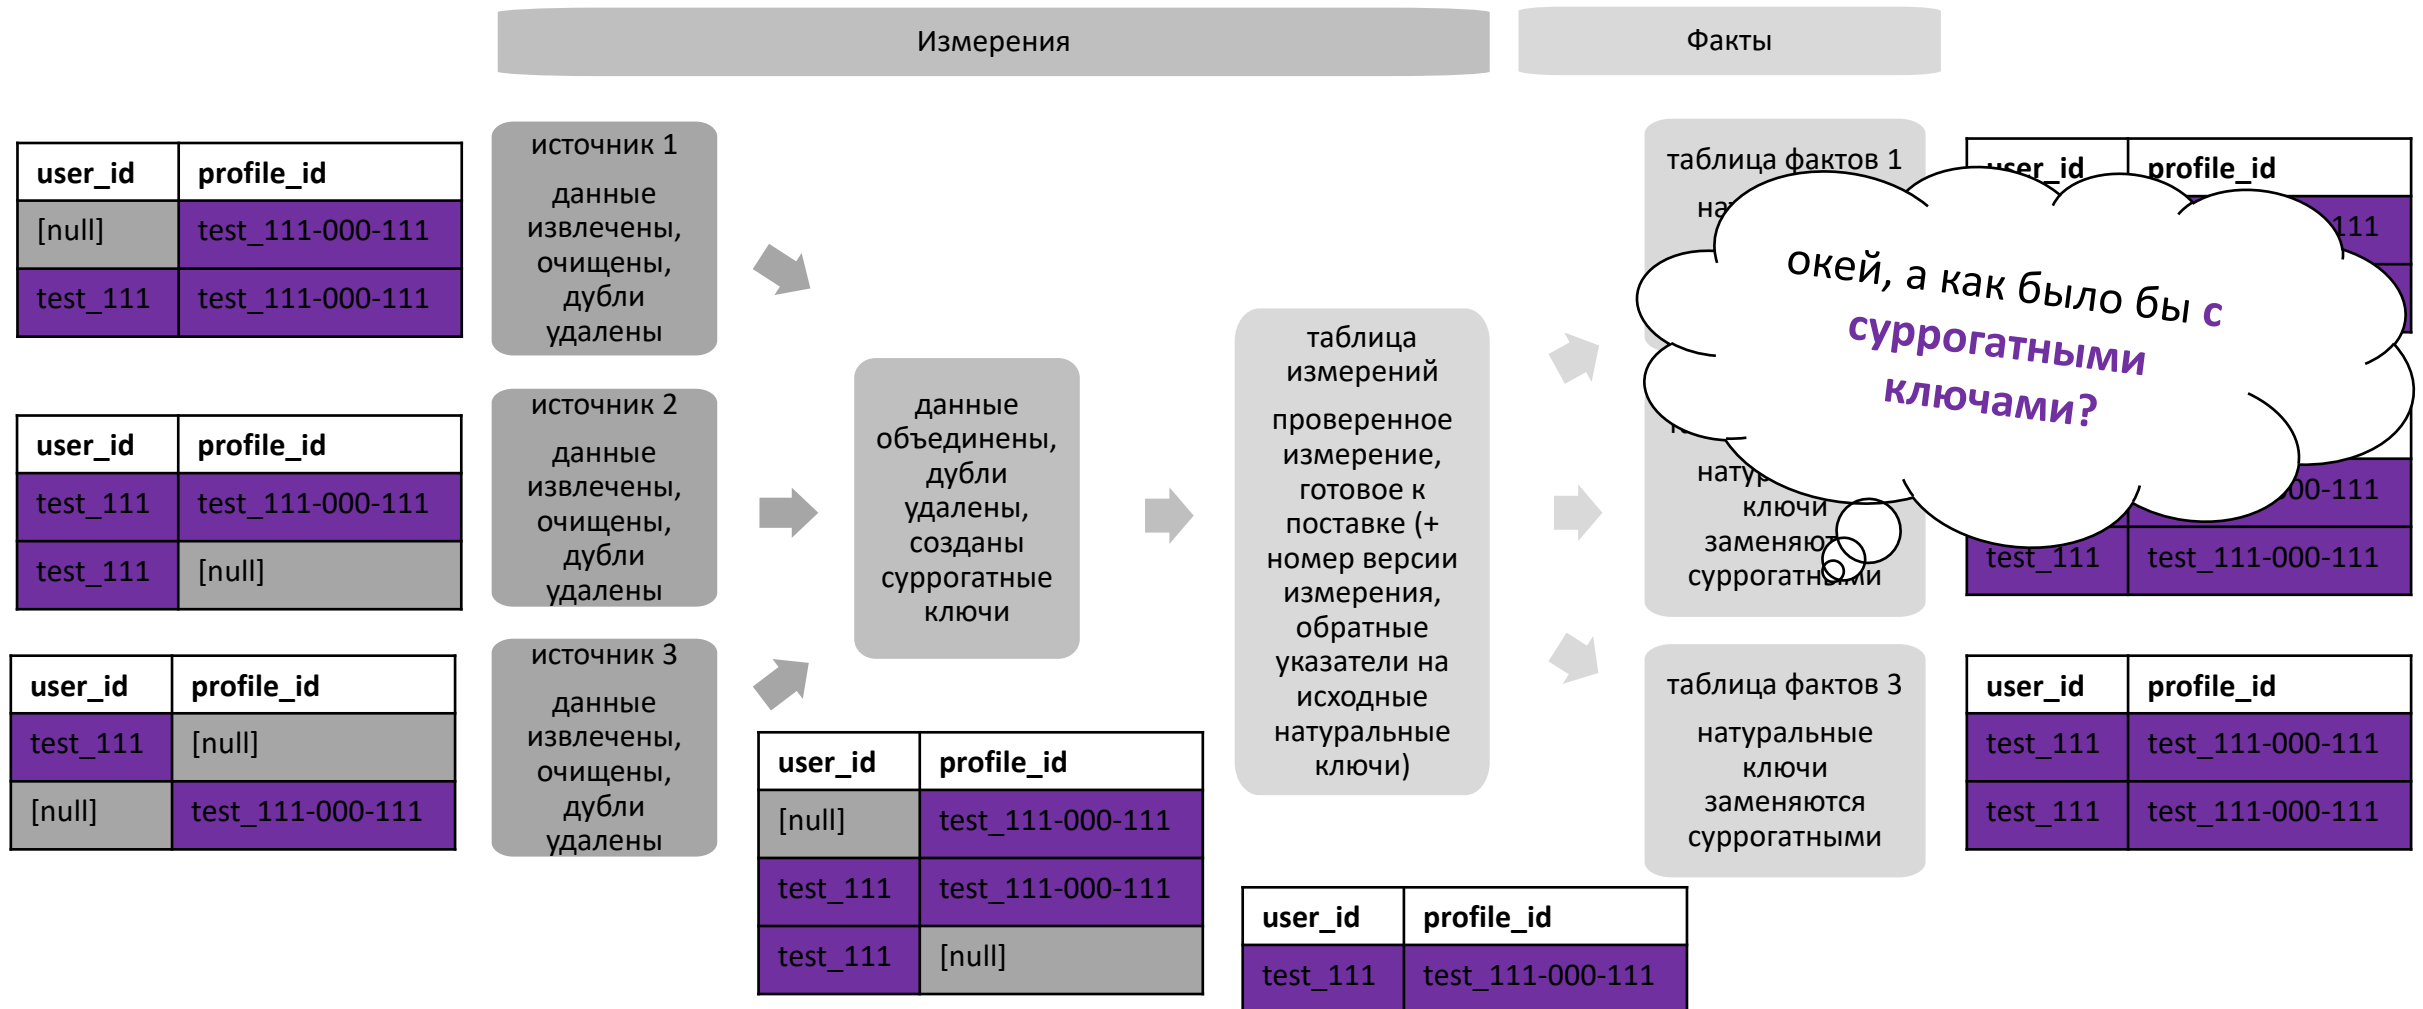
согласованные измерения - кратко



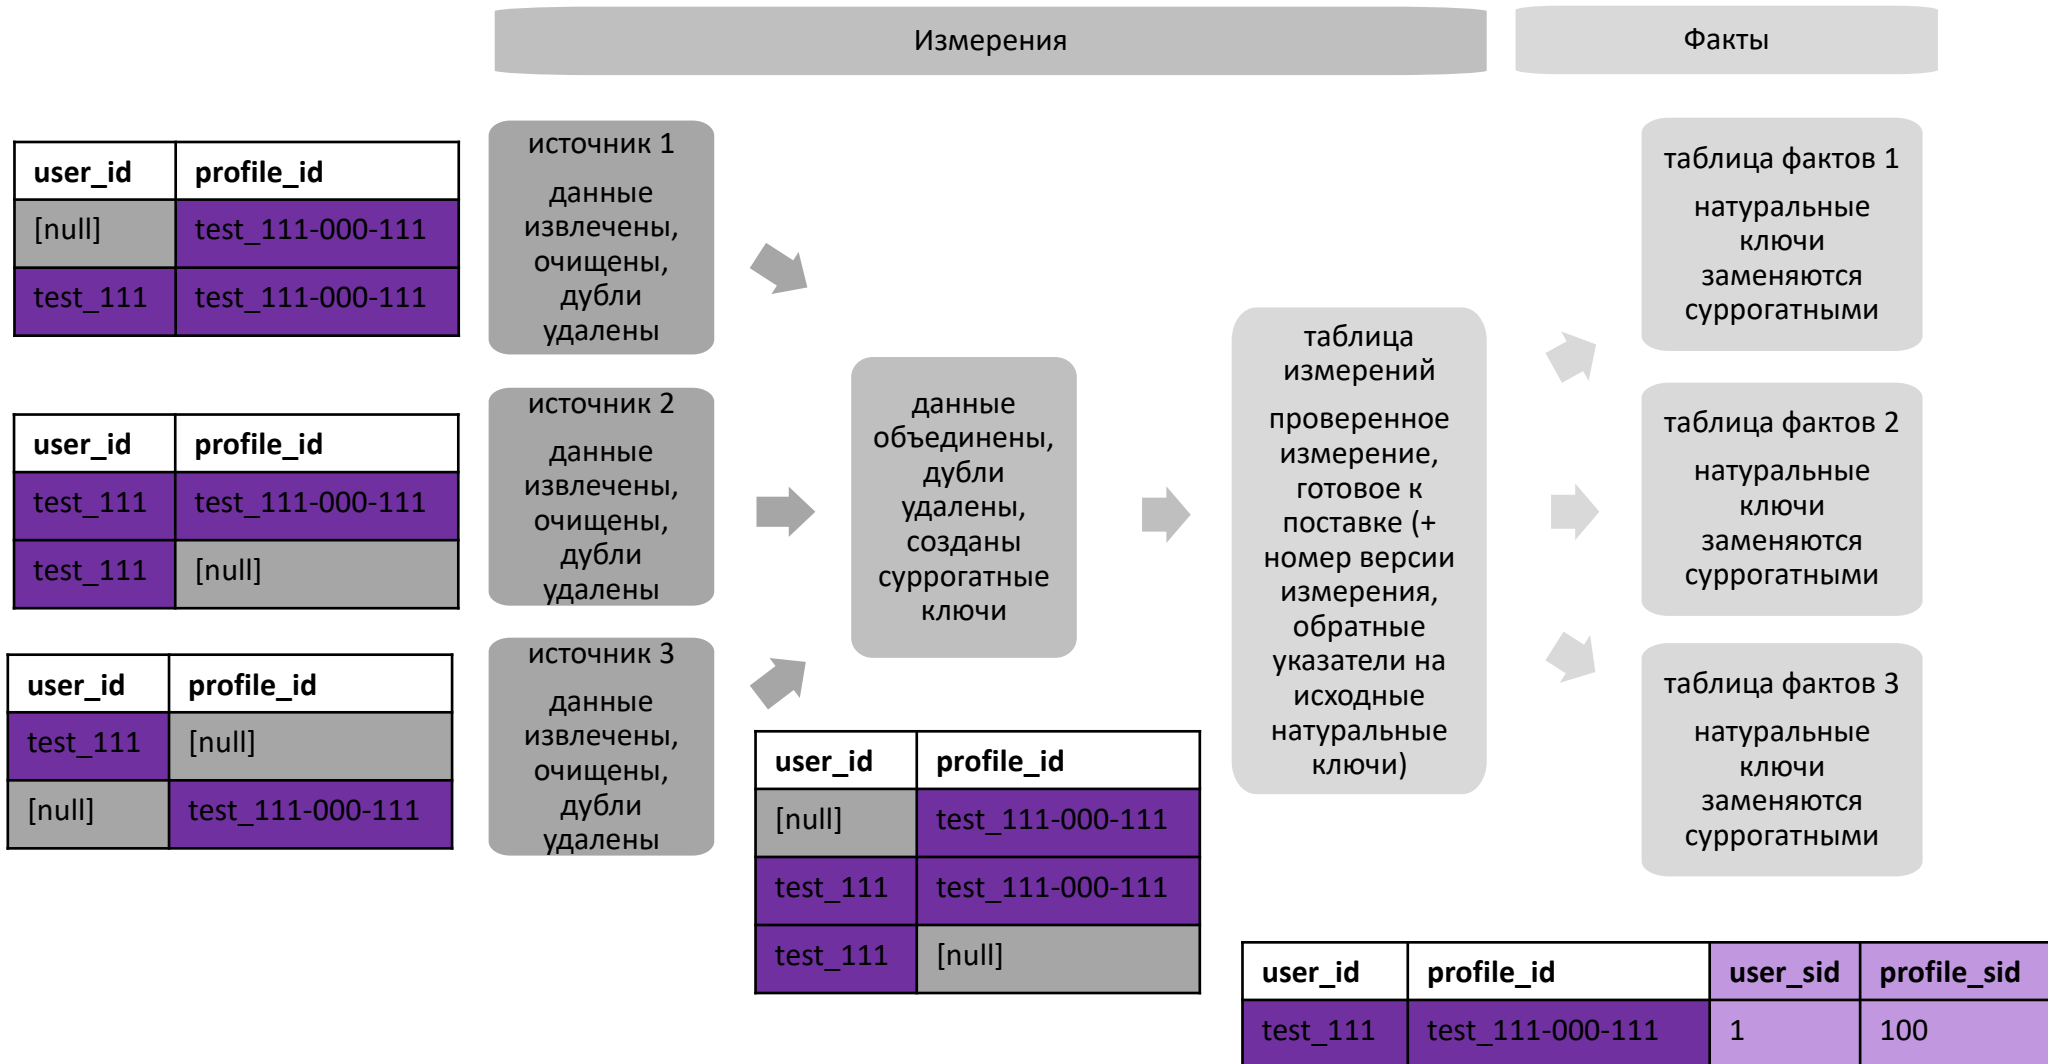
согласованные измерения - кратко



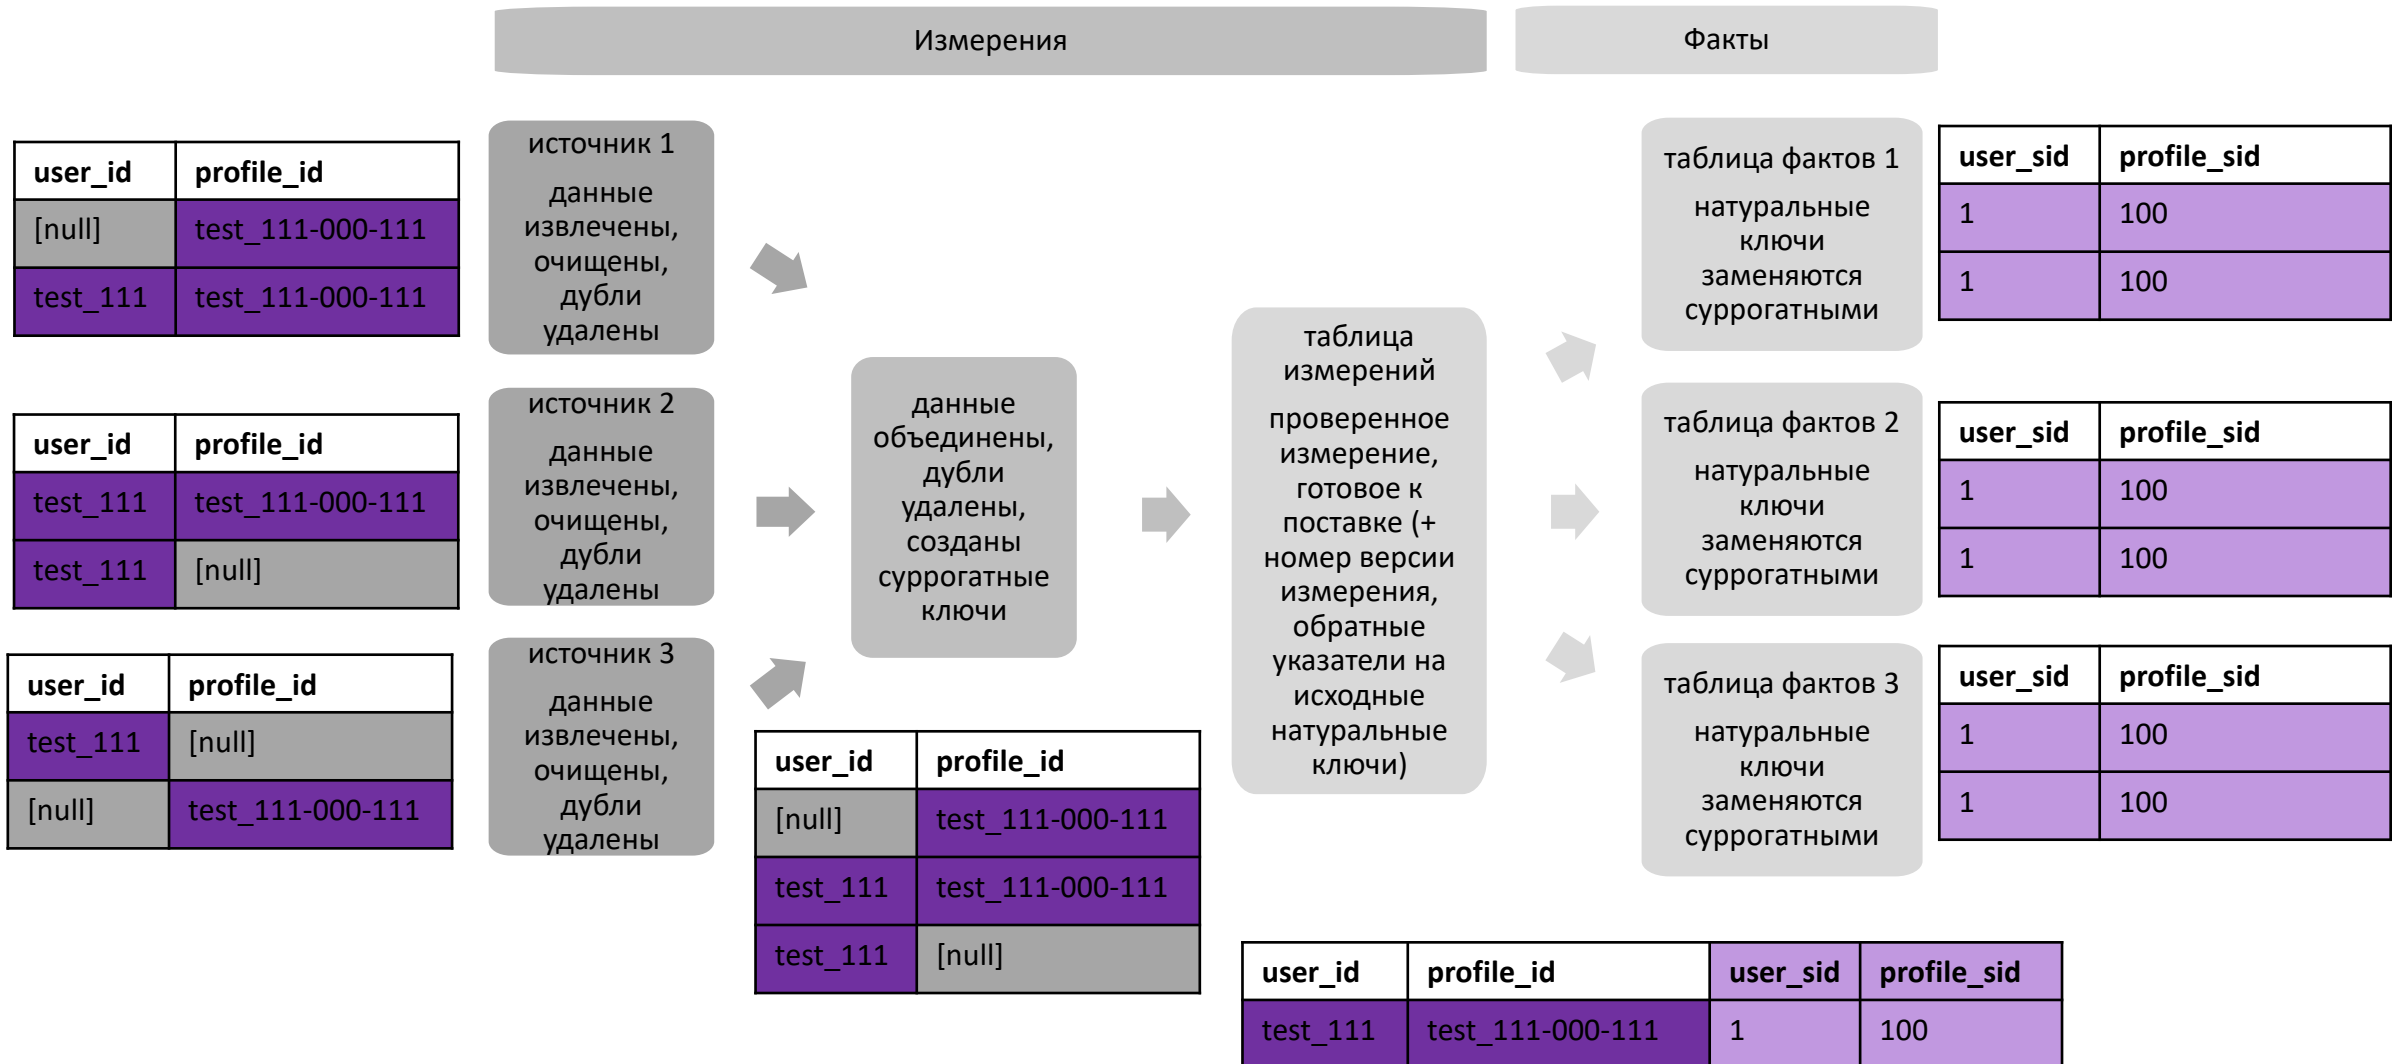
согласованные измерения - кратко



согласованные измерения - кратко



согласованные измерения - кратко



ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы
- простота и понятность для пользователей

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы
- простота и понятность для пользователей
- быстрота выполнения запросов

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы
- простота и понятность для пользователей
- быстрота выполнения запросов
- инкрементальная разработка (снизу вверх)

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы
- простота и понятность для пользователей
- быстрота выполнения запросов
- инкрементальная разработка (снизу вверх)
- единый источник правды
через согласованные измерения

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА

- ориентация на бизнес-процессы
- простота и понятность для пользователей
- быстрота выполнения запросов
- инкрементальная разработка (снизу вверх)
- единый источник правды
через согласованные измерения
- сохранение истории изменений

ОСНОВНЫЕ ЦЕННОСТИ ПОДХОДА


- ориентация на бизнес-процессы
- простота и понятность для пользователей
- быстрота выполнения запросов
- инкрементальная разработка (снизу вверх)
- *единый источник правды
через согласованные измерения*
- сохранение истории изменений

ИСТОЧНИКИ



Источники

О подходе Кимбалла можно прочитать здесь:



Спасибо
за внимание

